POSTGRESQL / JSONB

ОТЧЕТ К РАБОТЕ № 2

Сбор данных
и аналитика JSONB

Каталог стартапов - вариант 14

HTML, очистка данных и SQL-запросы

2026

1. Цель, задание и источник данных

Цель работы - исследовать слабоструктурированный веб-источник, извлечь сведения о стартапах, очистить их и представить в формате JSON. Для варианта 14 требуется более 300 записей с названием, временем основания, страной, сайтом, отраслью, основателями и привлеченными средствами.

Источник - каталог Failory Startups [1]. Использованы подробные карточки первых компаний в страновых подборках. Они размещены в обычном HTML и содержат заголовки, ссылки, теги и пары «поле - значение». Извлечение выполняется непосредственно из сохраненного HTML.

Примеры страниц:
https://www.failory.com/startups/united-states
https://www.failory.com/startups/india
https://www.failory.com/startups/germany

Элемент HTML-карточки	Исходный формат
Заголовок и ссылка	Название компании и URL ее сайта
Отраслевые теги	Несколько строковых категорий
Headquarters	Текстовое местоположение и страна
Year Founded	Четырехзначный год
Founders	Перечень имен или обозначение пропуска
Funding Amount	Текст: знак валюты, число, суффикс k/M/B
Дополнительные поля	Размер команды, стадия финансирования, инвесторы

В итоговом наборе 363 уникальных записей. Для воспроизводимости сохранены 37 HTML-страниц и manifest.json с данными об источниках. Набор является срезом каталога Failory, а не полной переписью стартапов мира.

Компания	Страна	Год	Funding Amount
Anthropic	United States	2021	$33.7B
DeepL	Germany	2017	$400M
Zepto	India	2021	$2.4B

Подробные карточки выделяются по h3.failory-card-title; поля извлекаются из table.info-table, а отрасли - из failory-badge. Компактные таблицы остальных компаний не используются, поскольку в них отсутствует часть требуемых полей.

2. Алгоритм извлечения и очистки

Обработка выполнена Python-скриптом. HTML-страницы сохраняются локально; повторный разбор возможен без изменения исходного среза. PostgreSQL используется для хранения JSONB и выполнения аналитических запросов.

Шаг	Операция
1. Получение	Загрузить страновые страницы и записать исходный HTML.
2. Выделение	Найти подробные карточки компаний, их названия, ссылки и поля.
3. Извлечение	Получить год, местоположение, отрасли, основателей и сумму.
4. Нормализация	Убрать лишние пробелы, привести массивы и числовые значения.
5. Проверка	Проверить допустимость года, URL и неотрицательность суммы.
6. Дедупликация	Не допускать повторов одной компании в итоговом наборе.
7. Выгрузка	Записать JSON и сводку сбора, затем загрузить документы в JSONB.

Правила очистки

HTML-сущности декодируются; неразрывные и повторные пробелы нормализуются. Пустые имена и отраслевые теги удаляются, повторы в массивах исключаются. Отсутствующие сведения не придумываются: основатели представлены пустым массивом, неизвестные суммы - null.

Страна извлекается из Headquarters, а не из названия подборки. URL проверяется на схему http/https и наличие имени хоста; фрагменты, ref и utm-параметры удаляются. Ссылка-заглушка превращается в null, исходное значение остается в website_raw.

Для идентификации используется нормализованное имя и домен сайта без www.; при отсутствии сайта - страна. Идентификатор образуется из SHA-256 этого сочетания. При повторе сохраняется первая запись и объединяются ссылки; возможные конфликты фиксируются отдельно.

Источник сообщает только Year Founded. Поэтому хранится год с точностью до года, без выдуманной даты 1 января. Значения k, M и B означают множители 1 000, 1 000 000 и 1 000 000 000. Исходная строка суммы сохраняется для проверки преобразования.

Обозначение валюты сохраняется буквально: $, €, A$, CN¥, R$, ¥. Знак $ не объявляется автоматически кодом USD. Курсы пересчета не используются; суммы с разными обозначениями валют не складываются и не ранжируются в одной группе.

3. Формат вывода и типы полей JSON

Файл startups.json содержит массив объектов: один объект на одну уникальную компанию. В PostgreSQL каждый объект сохраняется в поле data типа JSONB таблицы lab2.startups_json. Полный контракт полей:

Поле	JSON-тип и назначение
id	string: стабильный идентификатор компании
name	string: название компании
founded_year	integer | null: известный год основания
foundation_date	null: точная календарная дата источником не сообщается
foundation_precision	string: year либо unknown
country	string: страна из поля Headquarters
headquarters	string | null: местоположение как в источнике
website	string | null: очищенный URL сайта
website_raw	string | null: исходная ссылка для проверки
sectors	array<string>: уникальные отраслевые теги
founders	array<string>: имена основателей; [] при отсутствии
raised_money	object: amount (number | null), currency_label (string | null), raw (string | null)
funding_stage	string | null: указанная стадия финансирования
team_size_raw	string | null: исходное описание размера команды
investors	array<string>: перечисленные инвесторы
source_urls	array<string>: ссылки на исходные страницы и карточки
retrieved_at	string: время получения страницы в формате ISO 8601

JSON не имеет отдельного типа date: даты и время передаются строками по явно указанному формату. Значение null отличается от нуля; пустой массив основателей означает отсутствие сведений в выбранном источнике, а не отсутствие основателей у компании.

4. Пример документа и результат сбора

Сокращенный пример документа; имена основателей в иллюстрации заменены условными обозначениями. Полный набор полей находится в JSON-файле.


```
{
  "id": "startup_b11c5393bb34f94d",
  "name": "DeepL",
  "founded_year": 2017,
  "foundation_date": null,
  "foundation_precision": "year",
  "country": "Germany",
  "website": "https://www.deepl.com/",
  "sectors": ["AI", "Generative AI", "Software", "Translation Service"],
  "founders": ["FOUNDER_001"],
  "raised_money": {
    "amount": 400000000,
    "currency_label": "$",
    "raw": "$400M"
  }
}
```


Показатель	Значение
Уникальные компании	363
Успешно обработанные страницы	37
Страны в итоговых данных	37
Основатели не указаны	33
Сайт не указан или ссылка некорректна	1
Сумма финансирования неизвестна	15
Год основания неизвестен	2

Число записей строго больше 300. Веб-страницы сохранены локально, а manifest.json фиксирует URL, время получения, число карточек и SHA-256 исходного HTML. Точные даты основания не выдумывались.

5. Три простых запроса

Q1. Объем набора и пропуски

```
SELECT count(*) AS total_startups,
       count(*) FILTER (WHERE jsonb_array_length(data -> 'founders') = 0)
           AS founders_unknown,
       count(*) FILTER (WHERE data #>> '{raised_money,amount}' IS NULL)
           AS funding_unknown
FROM lab2.startups_json;
```

Результат: total_startups = 363; founders_unknown = 33; funding_unknown = 15. COUNT(*) считает все документы, FILTER отдельно подсчитывает пропуски.

Q2. Компании Индии, основанные с 2015 года

```
SELECT data ->> 'name' AS name,
       (data ->> 'founded_year')::integer AS founded_year,
       data ->> 'country' AS country,
       data ->> 'website' AS website
FROM lab2.startups_json
WHERE data ->> 'country' = 'India'
  AND (data ->> 'founded_year')::integer >= 2015
ORDER BY founded_year DESC, name, id;
```

Найдено 7 компаний. Оператор ->> извлекает текст, приведение ::integer позволяет сравнивать год как число. Сортировка по имени и id делает порядок однозначным.

Первые результаты Q2	Год	Страна
Weaver Services	2024	India
Akasa Air	2021	India
Rocket	2021	India

Q3. Компании с точным отраслевым тегом AI

```
SELECT data ->> 'name' AS name,
       data ->> 'country' AS country,
       data -> 'sectors' AS sectors
FROM lab2.startups_json
WHERE (data -> 'sectors') ? 'AI'
ORDER BY name, id;
```

Найдено 89 компаний. Оператор ? проверяет наличие точной строки в JSONB-массиве. Он не ищет подстроку: тег Generative AI сам по себе не удовлетворяет условию AI.

Первые результаты Q3: 1X, AI Hay, Acronis.

6. Расширенный запрос: статистика по секторам

Q4 группирует компании по стране, отраслевому тегу и буквальному обозначению валюты. В отчет попадают группы не менее чем из двух компаний. Запрос возвращает количество компаний, число известных сумм, сумму и среднее финансирование по источнику.

```
WITH expanded AS (
    SELECT DISTINCT s.id,
           s.data ->> 'country' AS country,
           btrim(x.sector) AS sector,
           s.data #>> '{raised_money,currency_label}' AS currency_label,
           (s.data #>> '{raised_money,amount}')::numeric AS amount
    FROM lab2.startups_json AS s
    CROSS JOIN LATERAL
         jsonb_array_elements_text(s.data -> 'sectors') AS x(sector)
    WHERE btrim(x.sector) <> ''
)
SELECT country, sector, currency_label,
       count(*) AS startups_count,
       count(amount) AS known_funding_count,
       sum(amount) AS total_reported_amount,
       round(avg(amount), 2) AS average_reported_amount
FROM expanded
GROUP BY country, sector, currency_label
HAVING count(*) >= 2
ORDER BY country, sector, currency_label NULLS LAST;
```

CROSS JOIN LATERAL раскрывает массив отраслей. DISTINCT оставляет одну строку на сочетание компании и отрасли. COUNT(amount), SUM и AVG игнорируют null; при отсутствии известных сумм результат SUM/AVG остается null. Нулевые значения вместо пропусков не подставляются.

Компания может относиться к нескольким секторам. Поэтому результаты разных секторных групп нельзя складывать для получения общего финансирования. Совпадающий маркер $ не доказывает совпадение международного кода валюты; расчет имеет описательный смысл только в пределах выбранной группы.

Результат Q4: 198 групп

Пример первых групп (Argentina):

Сектор	Метка	N / известно	Сумма	Среднее
Biotechnology	$	2 / 2	25 720 200	12 860 100
Credit Cards	$	2 / 2	1 012 000 000	506 000 000
FinTech	$	4 / 4	1 063 000 000	265 750 000

7. Расширенный запрос: лидеры финансирования

Q5 выбирает не более трех компаний в каждой паре «страна - обозначение валюты». Записи с неизвестной суммой или валютным маркером исключаются до ранжирования.

```
WITH amounts AS (
    SELECT id, data ->> 'name' AS name,
           data ->> 'country' AS country,
           data #>> '{raised_money,currency_label}' AS currency_label,
           (data #>> '{raised_money,amount}')::numeric AS amount
    FROM lab2.startups_json
    WHERE data #>> '{raised_money,amount}' IS NOT NULL
      AND data #>> '{raised_money,currency_label}' IS NOT NULL
), ranked AS (
    SELECT *, row_number() OVER (
        PARTITION BY country, currency_label
        ORDER BY amount DESC, name, id
    ) AS funding_rank
    FROM amounts
)
SELECT country, currency_label, funding_rank, name, amount
FROM ranked
WHERE funding_rank <= 3
ORDER BY country, currency_label, funding_rank, name, id;
```

ROW_NUMBER нумерует компании внутри группы. Основной критерий - убывание суммы; при равенстве используются название и стабильный id. Поэтому условие funding_rank <= 3 возвращает максимум три компании, а в малых группах - меньше трех.

Денежные значения извлекаются оператором #>> по вложенному пути и приводятся к numeric. Разные валютные обозначения не смешиваются. Это рейтинг по данным выбранного источника, не оценка стоимости компаний и не инвестиционная рекомендация.

Результат Q5: 129 строк

Фрагмент фактического результата:

Страна	Метка	Место	Компания	Сумма
Argentina	$	1	Ualá	910 000 000
Argentina	$	2	Pomelo	102 000 000
Argentina	$	3	Tapi	31 000 000
Australia	$	1	Canva	2 500 000 000
Australia	$	2	Employment Hero	521 500 000
Australia	$	3	Immutable Systems	277 400 000

8. Вывод и ограничения исследования

Для варианта 14 «Стартапы» исследован HTML-каталог Failory. Собран набор из 363 уникальных компаний по 37 сохраненным веб-страницам. Описаны исходная структура, типы полей, алгоритм извлечения и правила очистки. Результат представлен в JSON и пригоден для хранения в JSONB.

Разработаны ровно пять запросов: три простых для подсчета пропусков и выборок, два расширенных для групповой статистики и ранжирования. Запросы работают с массивами отраслей и вложенным денежным объектом, учитывают пропуски и не объединяют разные валютные маркеры.

Проверка реализации завершилась успешно: 24 проверки. Полные результаты всех пяти SQL-запросов сопоставлены с независимым расчетом Python, включая порядок строк, суммы, средние значения, пропуски и разрешение равенств при ранжировании.

Ограничения

Выборка включает подробные карточки в порядке страновых страниц каталога и не является случайной или репрезентативной. Данные отражают содержание сохраненных страниц, могут быть неполными и не проходили независимую финансовую проверку. Обозначение startup используется в смысле источника: каталог может включать давно основанные и уже крупные компании.

Для части записей неизвестны основатели, сайт или финансирование. Год основания не заменяется полной датой. Буквальные валютные обозначения сохраняются без предположения, что любой знак $ означает USD.

Использованные источники

1. Failory. Каталог стартапов и страновые подборки.
https://www.failory.com/startups

2. PostgreSQL 18. JSON Functions and Operators.
https://www.postgresql.org/docs/18/functions-json.html

3. PostgreSQL 18. Window Functions.
https://www.postgresql.org/docs/18/functions-window.html

Воспроизводимые материалы: исходные HTML и manifest.json; 01_collect.py; data/startups.json; data/collection_summary.json; 00_schema.sql; 01_load_data.sql; 02_queries.sql; results/queries.json; results/validation.json.